

**UNIVERSIDAD NACIONAL MAYOR DE SAN MARCOS
UNIVERSIDAD DEL PERÚ, DECANA DE AMÉRICA**



**FACULTAD DE INGENIERIA DE SISTEMAS E INFORMÁTICA
UNIDAD DE POSGRADO**

**DOCTORADO EN INGENIERIA DE SISTEMAS E INFORMATICA
CURSO: TOPICOS AVANZADOS EN COMPUTACION**

DOCENTE:

DR. MANUEL EDUARDO LOAIZA FERNÁNDEZ

**ESTIMACIÓN MULTITEMPORAL DEL RENDIMIENTO DE PAPA
MEDIANTE ORTOMOSAICOS MULTIESPECTRALES UAV (5 BANDAS),
DESMEZCLA LINEAL Y APRENDIZAJE AUTOMÁTICO CAMPAÑA 2025
JUNIN - PERÚ**

**PRESENTADO POR:
MG. JOHN GUERRA FLORES
LIMA – PERÚ
2025**

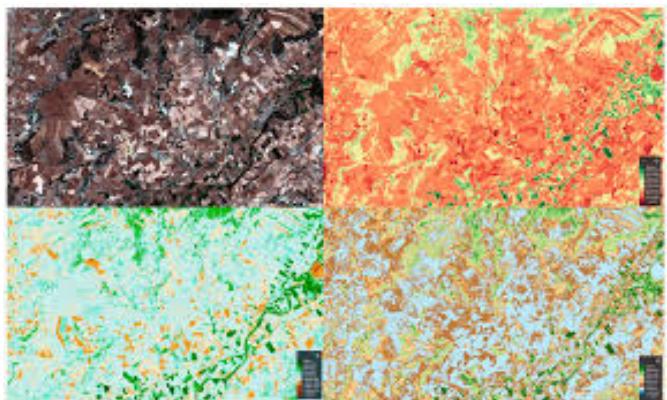
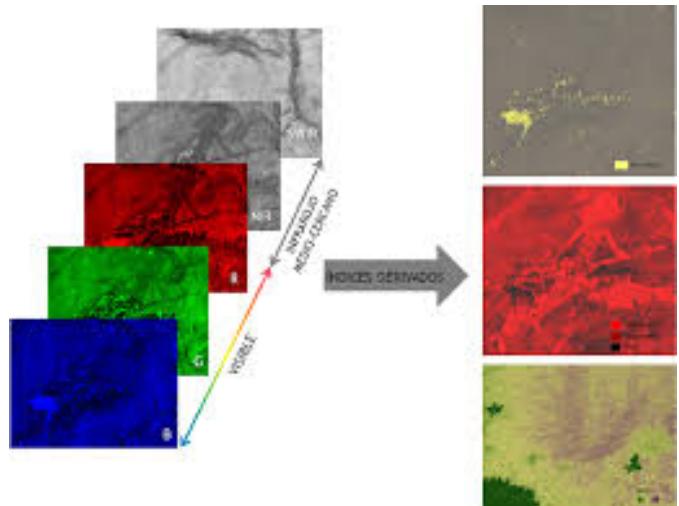




Introducción: Desafíos en el Cultivo de Papa

La papa es vital para la seguridad alimentaria y la economía peruana, especialmente en Junín. Sin embargo, su rendimiento varía significativamente debido a condiciones del suelo, manejo agronómico, disponibilidad hídrica, sanidad y fenología. Esta variabilidad dificulta la estimación temprana y la toma de decisiones.

La agricultura de precisión, con herramientas de teledetección como los UAV y sensores multiespectrales, ofrece una solución para caracterizar el cultivo con alta resolución espacial y de forma no destructiva.



Metodología Innovadora para la Estimación de Rendimiento

1

Ortomosaicos UAV Multiespectrales

Generación de imágenes detalladas a nivel de parcela con 5 bandas (B, G, R, RE, NIR) en tres fechas clave.

2

Desmezcla Lineal (LUM)

Estimación de la proporción de vegetación y suelo por píxel para mejorar la precisión de los índices espectrales.

3

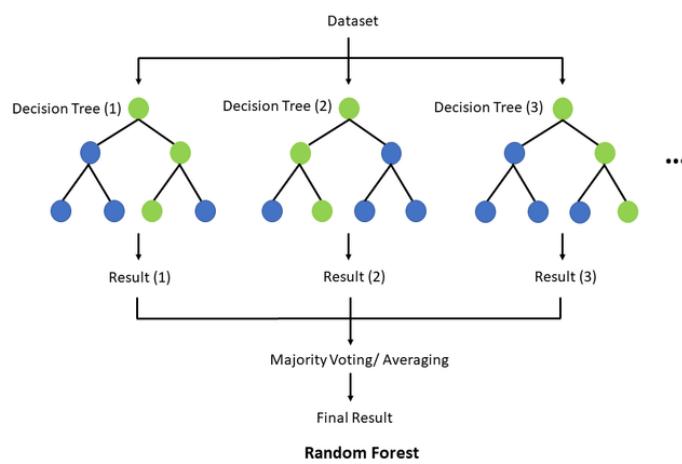
Aprendizaje Automático

Modelos predictivos (RandomForest) para capturar relaciones no lineales entre variables espectrales y rendimiento.

4

Enfoque Multitemporal

Integración de la evolución fenológica del cultivo para mejorar la capacidad predictiva de los modelos.



Problema General y Específicos

¿Cómo estimar de manera multitemporal y automática el rendimiento de papa (t/ha) en la campaña 2025 en Junín–Perú, utilizando ortomosaicos multiespectrales UAV de 5 bandas, aplicando segmentación vegetación–suelo, desmezcla lineal (LUM) y modelos de aprendizaje automático a escala de parcela?

- Estandarización de Ortomosaicos

Asegurar consistencia espacial y apilamiento multibanda adecuado.

- Integración Cartográfica

Recorte de ortomosaicos por unidad experimental (plot) para comparabilidad.

- Separación Vegetación–Suelo

Uso de segmentación (Otsu) y desmezcla lineal (LUM) para reducir el efecto de mezcla.

- Extracción de Variables

Cálculo de VF e índices espectrales (NDVI, SR, CHLGR, MARI, OSAVI, SAVI2) por parcela y fecha.

- Modelado Predictivo

Comparación de PLSR y RandomForest para predecir el rendimiento, con validación cruzada y control de valores extremos.



Justificación del Proyecto: Impacto y Relevancia

La estimación confiable y oportuna del rendimiento de papa es crucial para la planificación agronómica, logística y comercial en Junín. Los métodos actuales son limitados y no capturan la variabilidad del campo, llevando a un uso ineficiente de recursos.

Este proyecto integra segmentación automática (Otsu) y desmezcla lineal (LUM) para robustecer las variables extraídas, incorpora un enfoque multitemporal y aplica aprendizaje automático para modelar relaciones no lineales. Aporta un procedimiento reproducible para el monitoreo agronómico y la toma de decisiones en agricultura de precisión.

Objetivos y Alcances del Proyecto

Objetivo General:

Estimar de manera multitemporal y automática el rendimiento de papa (t/ha) en la campaña 2025 en Junín–Perú, utilizando ortomosaicos multiespectrales UAV de 5 bandas, aplicando segmentación vegetación–suelo, desmezcla lineal (LUM) y modelos de aprendizaje automático a escala de parcela (plot).



Procesamiento Multitemporal

Análisis de tres fechas de adquisición de imágenes (2025/10/02, 2025/11/03, 2025/12/10).



Análisis a Escala de Parcela

Procesamiento por unidad experimental definida en shapefile, generando productos por parcela.



Segmentación Automática

Implementación de Otsu y LUM para reducir la mezcla suelo–vegetación.

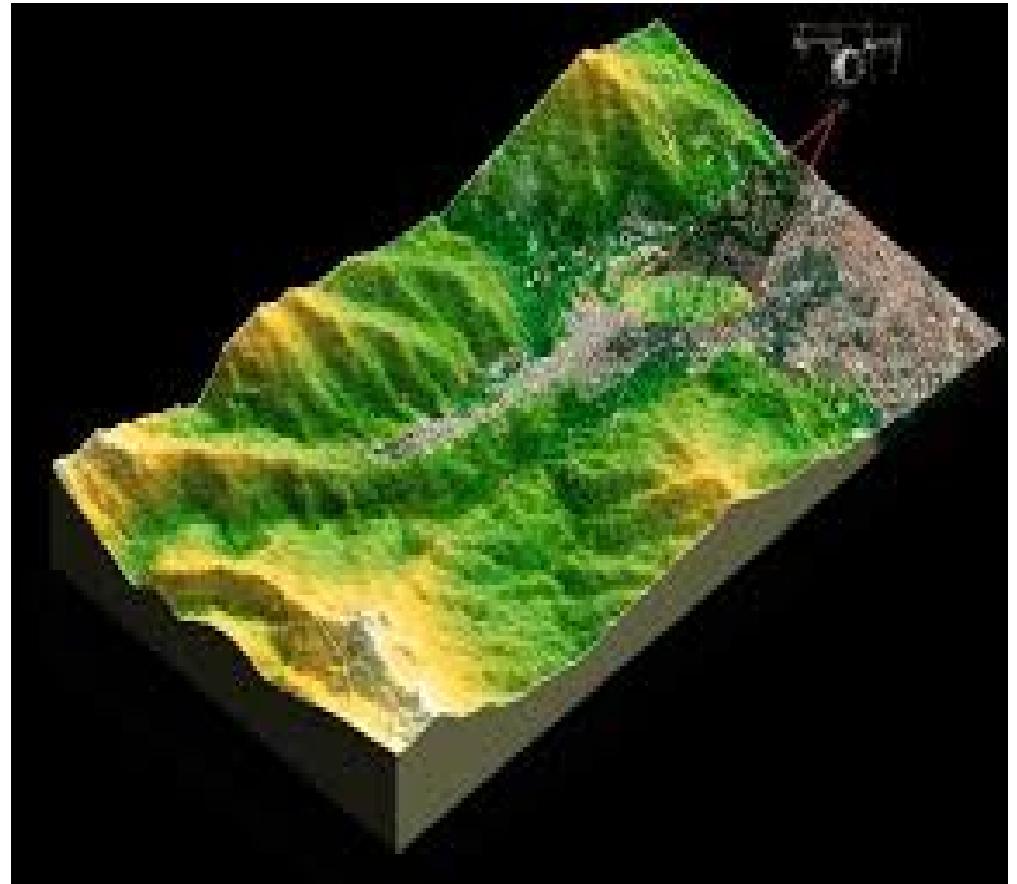


Modelado Predictivo

Evaluación de modelos PLSR y RandomForest con validación cruzada.

Marco Teórico: Fundamentos de Teledetección

La agricultura de precisión utiliza la teledetección para monitorear cultivos, permitiendo decisiones eficientes. El enfoque multitemporal es clave, ya que el rendimiento final es resultado de procesos acumulados durante el ciclo fenológico.



UAV y Sensores Multiespectrales

Los UAV ofrecen imágenes de alta resolución espacial y flexibilidad temporal, ideales para el análisis a escala de parcela. Sensores típicos incluyen bandas visible, red-edge y NIR, sensibles a pigmentos y estructura del dosel.

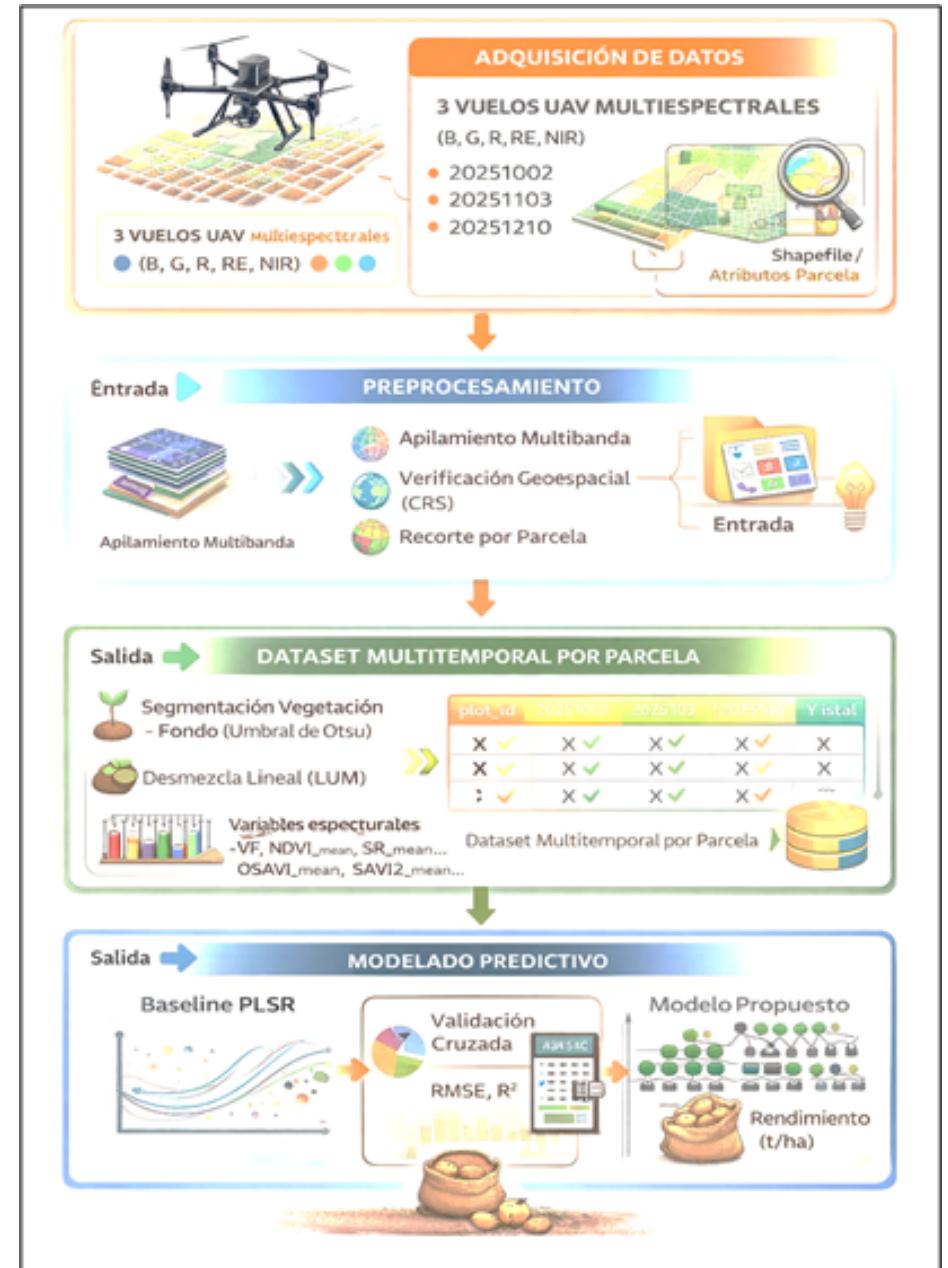
Respuesta Espectral de la Vegetación

La clorofila absorbe en el rojo, mientras que la reflectancia aumenta en el NIR. La región red-edge es sensible a variaciones de clorofila y estrés temprano, mejorando la detección de cambios sutiles.

Implementación: Flujo Metodológico

El proyecto se estructura en un flujo de trabajo multietapa, integrando teledetección UAV, procesamiento de imágenes multiespectrales, análisis multitemporal y modelado predictivo.

Se realizaron tres vuelos UAV en 2025 (octubre, noviembre, diciembre) en Sapallanga, Junín, complementados con datos de rendimiento de campo y un shapefile de parcelas. El entorno de desarrollo fue Jupyter Lab con Python, utilizando librerías como rasterio, geopandas, numpy, pandas, skimage y scikit-learn.



Resultados Clave: Dataset y Modelado

Se construyó un dataset multitemporal final con 202 parcelas y 25 columnas, incluyendo 21 variables predictoras y el rendimiento en t/ha. La distribución del rendimiento mostró alta asimetría y valores extremos, justificando una evaluación robusta con capP99.

Comparación de Modelos

PLSR (CV capP99)	29.46	0.173	baseline lineal
RandomForest (CV capP99)	28.04	0.251	modelo propuesto

El modelo RandomForest superó al PLSR, confirmando la naturaleza no lineal de la relación espectro-rendimiento.

Importancia de Variables

1	VF_20251002	32.83	2025/10/02
2	SAVI2_mean_20251002	16.50	2025/10/02
3	CHLGR_mean_20251210	4.14	2025/12/10

VF y SAVI2 de la primera fecha fueron las variables más influyentes.

La fecha 2025/10/02 aportó el 61% de la capacidad explicativa, destacando la importancia de la información temprana.

Conclusiones y Perspectivas Futuras



Flujo de Trabajo Exitoso

Implementación de un proceso reproducible para estimar el rendimiento de papa.



Dataset Multitemporal

Construcción de un dataset completo y reutilizable para análisis.



Modelo RandomForest Superior

Mejor desempeño en la predicción de rendimiento, capturando no linealidades.



Relevancia de Información Temprana

La primera fecha de vuelo fue la más determinante para la predicción.

Aunque el modelo mejoró, el R^2 moderado sugiere que factores no espectrales (suelo, manejo, clima) aún influyen significativamente. Futuras investigaciones podrían integrar estas covariables para mejorar la precisión.